

Project Documentation: Electricity Forecasting and Anomaly Detection

1. 프로젝트 개요

이 프로젝트의 목적은 두 가지입니다.

1. 전력 소비(`grid_P`)를 정확하게 예측하는 시계열 예측 모델 개발
2. 에너지 시스템에서 비정상적 이상 상태를 자동으로 탐지하는 이상 탐지 모델 개발

이를 위해 PostgreSQL DB에서 1시간 단위 전력 및 기상 데이터를 가져와, 두 개의 서로 다른 머신러닝/딥러닝 파이프라인으로 학습했습니다.

2. 데이터 소스 및 전처리

2.1 데이터 소스

`data_loader.py` 는 다음 데이터를 로드합니다.

- `grid_P` : 전체 전력 소비 (electricity total P)
- `pv_P` : 태양광 발전 전력
- `chp_P` : 발전기(코젠) 전력
- `Ta` : 기온
- `Igm` : 일사량

대상 테이블: `ems.reduced_measurement_1h`

2.2 피쳐

공통 피쳐는 다음과 같습니다.

- `grid_P` , `pv_P` , `chp_P` , `Ta` , `Igm`
- 시간 기반 사이클릭 특성
- `hour sin` , `hour cos`
- `dow sin` , `dow cos`
- `month_sin` , `month_cos`

총 11개 기본 피쳐를 사용합니다.

2.3 데이터 분할

시간 구간은 다음과 같습니다.

- 학습: 2018-01-01 ~ 2021-12-31
- 검증: 2022-01-01 ~ 2022-12-31
- 테스트: 2023-01-01 ~ 2023-12-31

2.4 결측값 처리

결측값은 모두 0 으로 채워집니다. 이 기준은 팀 내부 정책에 맞춘 처리 방식입니다.

2.5 이상 데이터 제거

학습 데이터에서 게이트웨이 장애 구간은 제거합니다. 제거 구간은 다음과 같습니다.

- 2020-02-13 ~ 2020-03-06
- 2020-08-20 ~ 2020-09-17
- 2021-11-15 ~ 2021-12-10
- 2022-05-06 ~ 2022-07-14

검증과 테스트 구간은 그대로 두고, 학습 데이터에서만 장애 구간을 제외합니다.

3. 모델 1: VMD-LSTM 예측 모델 (train_vmd_lstm.py)

3.1 목표

grid_P 전력 소비를 시계열 예측합니다. 특히 VMD(Variational Mode Decomposition)를 사용해 신호를 분해하고, LSTM 기반 모델로 미래 값을 예측합니다.

3.2 주요 방법

1. 데이터 로드 및 기본 피처 생성
2. VMD 로 grid_P 시계열을 4개의 IMF 성분으로 분해
3. 각 IMF에 대해 1시간 지연(lag) 피처를 추가하여 입력 피처 수를 11 -> 15 로 확장
4. 추가로 1주(168h), 2주(336h) 지연 피처를 생성
5. MinMaxScaler 로 입력과 타겟을 정규화
6. SEQ_LEN=24 로 시퀀스 생성
7. LSTM + attention 모델 학습
8. 검증 손실로 early stopping
9. 최종 모델 및 스케일러 저장

3.3 모델 구조

LSTMForecaster 는 다음을 포함합니다.

- 2-layer LSTM
- Attention pooling
- Fully connected 출력층
- HuberLoss 손실 함수

3.4 하이퍼파라미터

- VMD: K=4 , alpha=2000
- 시퀀스 길이: 24
- 배치 크기: 256
- 학습률: 1e-3
- 히든 차원: 192
- 레이어 수: 2
- 드롭아웃: 0.2
- epochs: 100
- early stopping patience: 15

3.5 주요 결과

MLflow에 기록된 대표 결과는 다음과 같습니다.

- 검증 MAE: 약 22,460 W
- 검증 RMSE: 약 43,827 W
- 검증 MAPE: 약 25.50%
- 테스트 MAE: 약 26,252 W
- 테스트 RMSE: 약 45,761 W
- 테스트 MAPE: 약 57.42%

3.6 해석

- 검증 대비 테스트 오차가 크게 상승하는 경향이 있습니다.
- 이는 테스트 분포가 검증 분포와 다르거나 모델이 과적합되었을 가능성을 시사합니다.
- VMD 기반 분해와 lag 특성 추가는 시계열 패턴을 포착하려는 시도입니다.

4. 모델 2: IF + LSTM-AE 이상 탐지 (train_anomaly_ifae.py)

4.1 목표

정상/비정상 구간을 감지하여 이상 상태를 분류합니다. 두 가지 접근을 앙상블합니다.

4.2 주요 방법

1. 데이터 로드 및 피처 생성
2. MinMaxScaler 정규화
3. SEQ_LEN=24 으로 시퀀스 생성
4. LSTM Autoencoder 학습
5. 재구성 오차 기반 이상 임계치 계산
6. Isolation Forest로 밀도 기반 이상탐지
7. 두 모델을 합산해 최종 이상 여부 결정
8. pseudo-label을 사용해 평가

4.3 LSTM-AE 구조

LSTMAutoencoder 는 다음을 포함합니다.

- 2-layer LSTM 인코더
- Attention 기반 시퀀스 풀링
- Latent bottleneck
- 2-layer LSTM 디코더
- 출력 재구성층

4.4 이상 탐지 논리

- AE 재구성 오차가 임계치 이상이면 AE 이상
- IF 예측 결과가 -1 이면 IF 이상
- 두 모델 모두 이상이면 HIGH
- 하나만 이상이면 LOW
- 모두 정상일 경우 NORMAL

4.5 임계치 설정

- AE: $\text{mean}(\text{train_MSE}) + k * \text{std}(\text{train_MSE})$
- $k=2.0$ 을 사용하여 민감도를 높임
- IF: $\text{contamination}=0.15$

4.6 pseudo-label 정의

- 2022-05-06 ~ 2022-07-14 구간을 이상으로 설정
- 검증에는 해당 구간을 평가 레이블로 사용
- 테스트 구간에는 알려진 이상 구간이 없으므로 정상으로 간주

4.7 하이퍼파라미터

- 시퀀스 길이: 24
- 배치 크기: 1024
- 학습률: $1e-3$
- 히든 차원: 128
- latent dim: 32
- 드롭아웃: 0.2
- epochs: 100
- early stopping patience: 15
- IF contamination: 0.15
- threshold k: 2.0

4.8 주요 결과

`train_anomaly_ifae.py` 실행 결과 로그에서 관찰된 성능:

- 검증 AUC: 약 0.547
- 검증 F1: 약 0.294
- 검증 Precision: 약 0.244
- 검증 Recall: 약 0.368
- 테스트에서는 pseudo-label이 단일 클래스이므로 AUC가 계산 불가(nan)
- 테스트 F1/precision/recall이 0 인 것은 테스트 표본에 이상 레이블이 없거나 이상이 탐지되지 않았기 때문

4.9 해석

- 검증에서는 AE+IF 가 어느 정도 이상을 포착하지만 성능이 낮습니다.
- 테스트에서는 희소한 이상 레이블 특성 때문에 평가가 매우 불안정합니다.
- 이상 탐지는 실제 운영 환경에서는 임계치, 레이블 정의, 모델 양상불 규칙을 더 정교하게 조정해야 합니다.

5. MLflow 사용

5.1 실험 구성

각 스크립트는 MLflow를 통해 실험을 기록합니다.

- `train_vmd_lstm.py` : SSA-IPSO-LSTM 실험
- `train_anomaly_ifae.py` : LSTM-AE-Anomaly 실험

5.2 기록 항목

- 파라미터: 모델 하이퍼파라미터, 스케일러, sequence 길이 등
- 메트릭: 손실, MAE, RMSE, MAPE, F1, AUC 등
- 아티팩트: 학습된 모델 파일, 스케일러 파일

5.3 저장 위치

현재 MLflow는 파일 백엔드로 `file:///workspace/mlruns` 에 저장되고 있습니다.

5.4 주의점

MLflow 파일 백엔드는 2026년 이후 deprecated 상태입니다. 장기적으로는 `sqlite:///mlflow.db` 등 데이터베이스 백엔드로 이전하는 것이 좋습니다.

6. 현재 코드베이스 구성

주요 파일

- `data_loader.py` : DB 연결, 원시 데이터 로드, 피쳐 생성, train/val/test 분할
- `train_vmd_lstm.py` : VMD-LSTM 기반 전력 소비 예측 모델
- `train_anomaly_ifae.py` : LSTM-AE + Isolation Forest 기반 이상 탐지 모델
- `requirements_runpod.txt` : 필요한 Python 패키지 목록

출력 결과

- `outputs/models/vmd_lstm_grid_electricity.pt`
 - `outputs/models/vmd_lstm_scaler.pkl`
 - `outputs/models/anomaly_lstm_mae.pt`
 - `outputs/models/anomaly_iforest.pkl`
 - `outputs/models/anomaly_scaler.pkl`
-

7. 실행 방법

예측 모델

```
pip install -r requirements_runpod.txt
python train_vmd_lstm.py
```

이상 탐지 모델

```
pip install -r requirements_runpod.txt
python train_anomaly_ifae.py
```

8. 권장 개선 방향

8.1 예측 모델

- 테스트 MAPE가 높으므로 추후 개선 필요

- VMD 분해 구성을 재검토하거나 더 많은 시퀀스 길이, 추가 피쳐 실험
- 정규화 정책과 학습/평가 분포 차이를 확인

8.2 이상 탐지 모델

- pseudo-label 정의를 확장하여 더 많은 이상 사례 확보
- 임계치 `k` 값과 `IF contamination` 을 민감도에 맞게 튜닝
- 재구성 오차 대신 다른 이상 점수(예: Mahalanobis 거리) 고려

8.3 MLflow

- 파일 스토어 대신 SQLite/서버 백엔드로 전환
 - 중요한 Run에 `mlflow.log_model` 을 추가해 모델 배포 준비
-

9. 요약

이 프로젝트는 에너지 시스템에서 전력 소비 예측과 장애 기반 이상 탐지를 동시에 다루는 데이터 사이언스 파이프라인입니다. 데이터를 DB에서 가져와 시계열 특성을 만들고, VMD 분해 및 LSTM 기반 예측을 수행하며, LSTM-AE와 Isolation Forest의 앙상블로 이상을 탐지합니다.

현재는 모델 학습과 MLflow 기록이 정상 동작하지만, 성능 개선 여지가 있으며 특히 테스트 일반화와 이상 탐지 평가가 중요합니다.